TP INTEGRADOR · OPERACIONES DE APRENDIZAJE AUTOMÁTICO II · CEIA – FIUBA

# Plataforma de predicción de riesgo de ACV

*Un modelo en producción: orquestado, versionado, seguro y con datos trazables.*

Cecilia Villanueva

**~5.100**
pacientes (Kaggle)

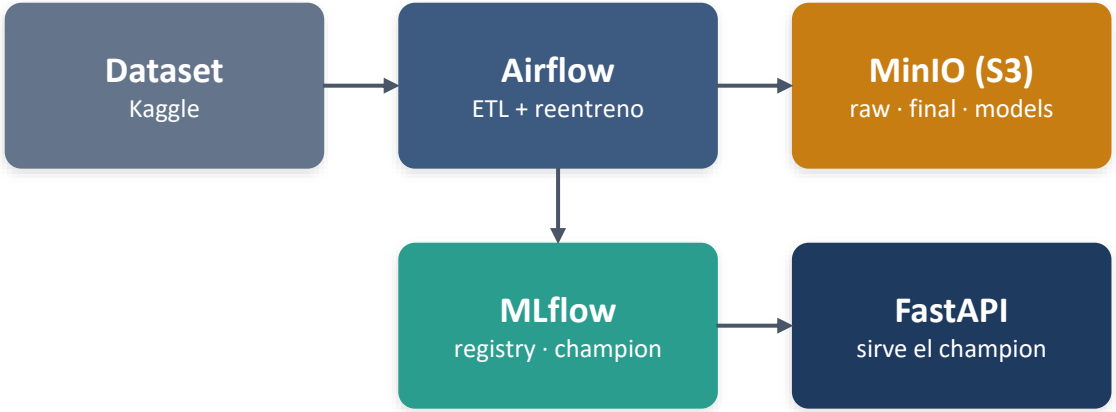
**2**
DAGs · ETL y reentrenamiento

**2**
capas integradas al stack

**1**
comando para levantar todo

# Arquitectura: el stack y dos capas integradas

STACK DOCKER · ORQUESTACIÓN + CICLO DE VIDA




**Champion / challenger:** el modelo nuevo se promueve solo si mejora el F1. Rollback = mover el alias, sin reiniciar la API.

**Airflow entrena → MLflow elige el champion → la API segura lo sirve → el data lake guarda cada versión**

INTEGRADAS AL STACK

- TP1+TP7 — API REST segura
- TP6 — Data lake versionado

EXPLORADAS PARA COMPARAR

- TP2–3 — GraphQL · gRPC
- TP4 — Streaming + drift
- TP5 — Federado FedAvg

# Qué aprendí de los mini-TPs

## INTEGRADAS AL STACK

### TP1 + TP7 · API REST segura

**401 · 403 · 429**

Sin token, rol sin permiso, ráfaga de consultas. Auditoría con hash, sin el dato clínico.

### TP6 · Data lake versionado

**3 etapas**

Datos crudos, datos limpios y modelos. Cada versión se guarda aparte y nunca se pisa.

## EXPLORADAS PARA COMPARAR (MISMO MODELO)

### TP2–3 · GraphQL y gRPC

**−59 %**

bytes con GraphQL vs REST

### TP4 · Streaming

**24 ms**

p95 global y detector de drift

### TP5 · Federado

**0.78 → 0.52**

IID vs non-IID (softmax)

# Demo en vivo

1. **Airflow :8080**
   Los dos DAGs en verde: ETL y reentrenamiento

2. **MLflow :5000**
   El alias champion marca el modelo en producción

3. **API REST segura :8009**
   401 → login 200 → ráfaga 429 → invitado 403 → auditoría

4. **Data lake en MinIO :9001**
   Etapas, models/vN y el puntero champion.json

## Límites y próximo paso

- **Monitoreo:** que la alerta de drift dispare el reentrenamiento en Airflow
- **Streaming simulado** con cola en memoria, no Kafka
- **Federado didáctico** sobre softmax, no sobre el RandomForest